Fundamentos de la Ciencia de Datos - 2026

Trabajo Práctico Especial

Grupo 9

Campo Zambotti, Agustin
Najurieta, Constanza Belén
Rosani, Nicolas Javier

Tutor
Orlando, José Ignacio

1. Introducción

1.1 Introducción y contexto del problema

El presente trabajo se centra en el análisis de la enfermedad renal crónica (CKD) a partir de un conjunto de datos de salud y nutrición de Estados Unidos correspondiente al período 2021–2023. Esta enfermedad representa una problemática relevante para la salud, ya que afecta la capacidad de los riñones para filtrar la sangre y eliminar los desechos del organismo.

El objetivo es explorar las variables clínicas, demográficas y socioeconómicas del conjunto de datos para identificar posibles patrones y relaciones con la función renal, mediante técnicas de análisis exploratorio, limpieza y análisis estadístico.

1.2 Conjunto de datos utilizado

El dataset que utilizamos, CKD_NHANES_2021_2023.csv, contiene 11933 registros y 29 variables. Incluye información sobre edad, sexo, grupo étnico, nivel educativo, ingresos, medidas corporales, presión arterial, análisis de sangre y orina, antecedentes de diabetes y tabaquismo, y variables relacionadas con la función renal, como la tasa de filtrado glomerular estimada (eGFR) y el estadio de enfermedad renal (ckd_stage).

1.3 Problemas identificados y correcciones realizadas

Durante la exploración inicial se detectaron valores faltantes, códigos especiales en algunas variables categóricas y valores numéricos extremadamente pequeños que podían corresponder a errores de representación.

Como parte de la limpieza, los códigos que representaban respuestas desconocidas o negativas a responder fueron reemplazados por valores faltantes. También se identificaron y recodificaron valores prácticamente iguales a cero en las variables age y poverty_income_ratio.

Además, se detectaron valores atípicos en distintas mediciones clínicas. Estos no fueron eliminados automáticamente, ya que podrían representar situaciones reales. Se conservaron los registros original y se creó una copia del dataset para realizar las modificaciones, evitando perder información.

2. Análisis exploratorio de los datos

En primer lugar, se realizó una exploración general del conjunto de datos utilizando Python y las bibliotecas Pandas, NumPy, Matplotlib y Seaborn, donde nos encontramos con 29 variables relacionadas con características demográficas, socioeconómicas, medidas corporales, presión arterial y distintos indicadores obtenidos mediante análisis de sangre y orina. También incluye información sobre antecedentes de diabetes, tabaquismo y la clasificación de la enfermedad renal crónica.

Durante la exploración inicial se observó que algunas variables presentan una cantidad considerable de valores faltantes, especialmente aquellas relacionadas con estudios clínicos y tratamientos. También se identificaron diferencias en la cantidad de registros disponibles según la variable analizada. Por otro lado, se encontraron algunos valores extremos en variables como la altura, la albúmina urinaria y la relación albúmina-creatinina, que fueron considerados para la etapa de limpieza.

Además, se observaron relaciones entre algunas variables, como el índice de masa corporal y el peso, y entre la edad y la tasa de filtración glomerular estimada. Estas primeras observaciones permitieron conocer mejor la información disponible y sirvieron como punto de partida para plantear las hipótesis que se analizarán en los siguientes apartados.

3. Hipótesis planteadas y resolución

A partir de la exploración inicial del conjunto de datos, seleccionamos variables demográficas, clínicas y socioeconómicas para evaluar su relación con la enfermedad renal crónica (*CKD*). Planteamos tres hipótesis propias (univariada, bivariada y multivariada) y tres hipótesis propuestas por la cátedra.

Para el contraste de estas hipótesis consideramos únicamente a los participantes con estado renal conocido (*ckd_status* 0 o 1, descartando los registros clasificados como *Unknown*, lo que nos dejó una muestra de 6326 participantes con CKD y 3592 sin CKD).

3.1. La prevalencia de enfermedad renal crónica se incrementa significativamente con la edad - *Univariada*

3.1.1. Definición de la hipótesis

Hipótesis Nula (H0): La proporción de personas de 60 años o más dentro del grupo con CKD es menor o igual al 50% ($p \leq 0.50$).

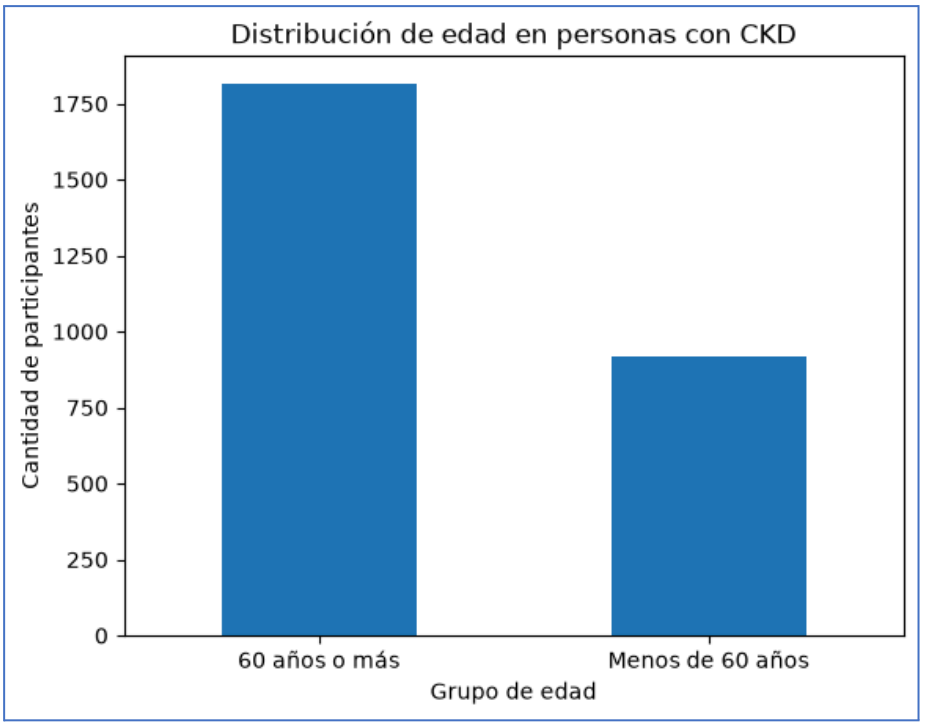
Hipótesis Alternativa(H1): La proporción de personas de 60 años o más dentro del grupo con CKD es estrictamente superior al 50% ($p > 0.50$).

3.1.2. Estrategia de abordaje

Para introducir esta idea, filtramos el subgrupo de pacientes diagnosticados con CKD (df_ckd) y contabilizamos cuántos de ellos tenían 60 años o más. Para evaluar si la proporción observada superaba de forma estadísticamente significativa el umbral del 50%, aplicamos una prueba binomial exacta (binomtest de scipy.stats) con una alternativa de cola derecha.

3.1.3. Resultados obtenidos y discusión

Dentro del grupo de 2734 personas con CKD, un total de 1815 resultaron tener 60 años o más, lo que equivale al 66,39% de los casos. La prueba binomial arrojó un valor $p = 3,60\,x\,10^{-67}$, sensiblemente menor al nivel de significancia del 5% $(\alpha = 0,05)$. Por lo tanto, rechazamos la hipótesis nula (H0) y aceptamos la hipótesis alternativa (H1): quedó totalmente demostrado de que más de la mitad de los pacientes con CKD pertenecen a la franja etaria de 60 años o más.



3.2. Existe una asociación significativa entre el diagnóstico de diabetes y la presencia de enfermedad renal crónica - *Bivariada*

3.2.1. Definición de la hipótesis

Hipótesis Nula (H0): El diagnóstico de diabetes y la presencia de la enfermedad renal crónica son variables independientes, es decir, no están asociadas.

Hipótesis Alternativa(H1): Existe una asociación estadísticamente significativa entre el diagnóstico de diabetes y la presencia de enfermedad renal crónica.

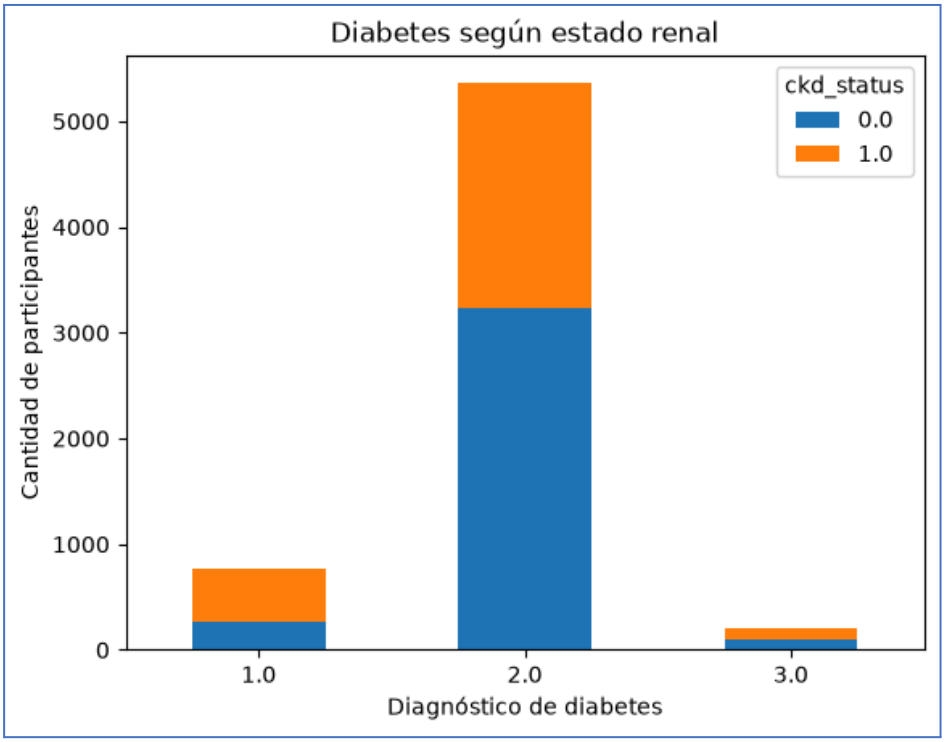
3.2.2. Estrategia de abordaje

Construimos una tabla de contingencia cruzando la variable de diagnóstico de diabetes (diabetes_diagnosed) con la presencia de CKD (ckd_status). Para evaluar si las diferencias observadas en las proporciones responden al azar o a una verdadera dependencia entre las condiciones, aplicamos una prueba de Chi-cuadrado de independencia

3.2.3. Resultados obtenidos y discusión

La prueba de Chi-cuadrado arrojó un estadistico $X^2 = 187,31$ con 2 grados de libertad y un valor $p = 2,12\,x\,10^{-41}$. Al ser infinitamente menor que $\alpha = 0,05$, rechazamos la hipótesis nula (H0) y confirmamos la asociación entre ambas condiciones. La visualización de los

datos permite apreciar que la proporción de personas con CKD es considerablemente mayor en el grupo que padece diabetes en comparación con quienes no presentan la afección.



3.3. La edad, el diagnóstico de diabetes y la presión arterial sistólica se relacionan conjuntamente con la presencia de enfermedad renal crónica - *Multivariada*

3.3.1. Definición de la hipótesis

Hipótesis Nula (H0): El conjunto de variables formado por edad, diabetes y presión arterial sistólica no aporta capacidad explicativa ni predictiva significativa sobre la presencia de CKD.

Hipótesis Alternativa(H1): La combinación multivariada de edad, diabetes y presión arterial sistólica se relaciona significativamente con la presencia de CKD.

3.3.2. Estrategia de abordaje

Par analizar cómo actúan estas tres variables de manera conjunto, implementamos un modelo de regresión logística a través de un pipeline de scikit-learn:

1. Imputamos valores faltantes (mediana en numéricas y moda en categóricas).
2. Escalamos las variables continuas (age y bp_systolic) mediante StandardScaler y codificamos la condición de diabetes con OneHotEncoder.

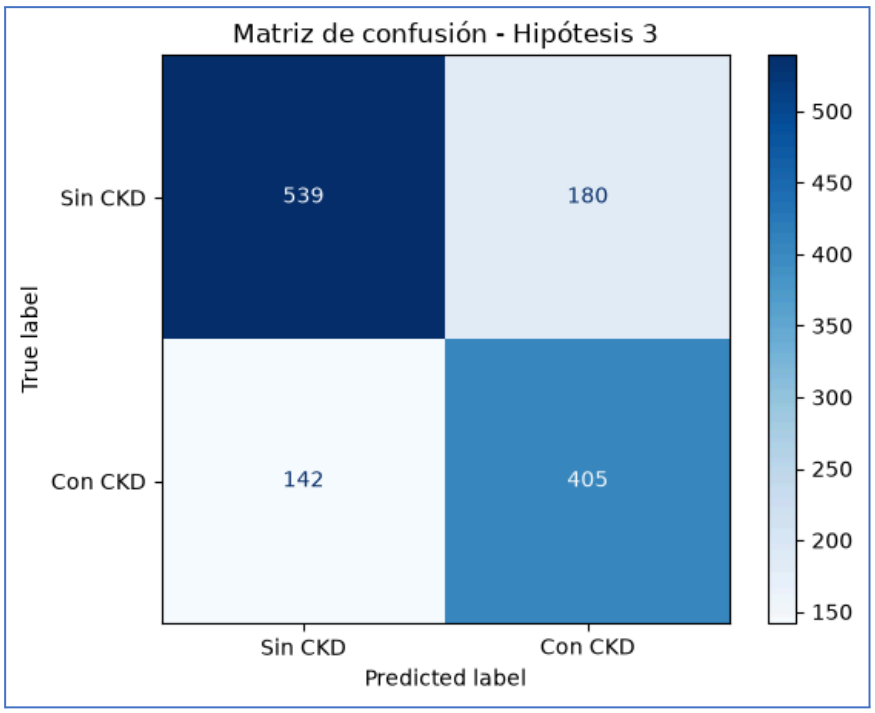
3. Dividimos el dataset en conjuntos de entrenamiento (80%) y prueba (20%) de forma estratificada.
4. Para evaluar el desempeño del modelo sobre el conjunto de prueba, construimos la matriz de confusión y la curva ROC, analizando las métricas de sensibilidad (recall), exactitud y el área bajo la curva.

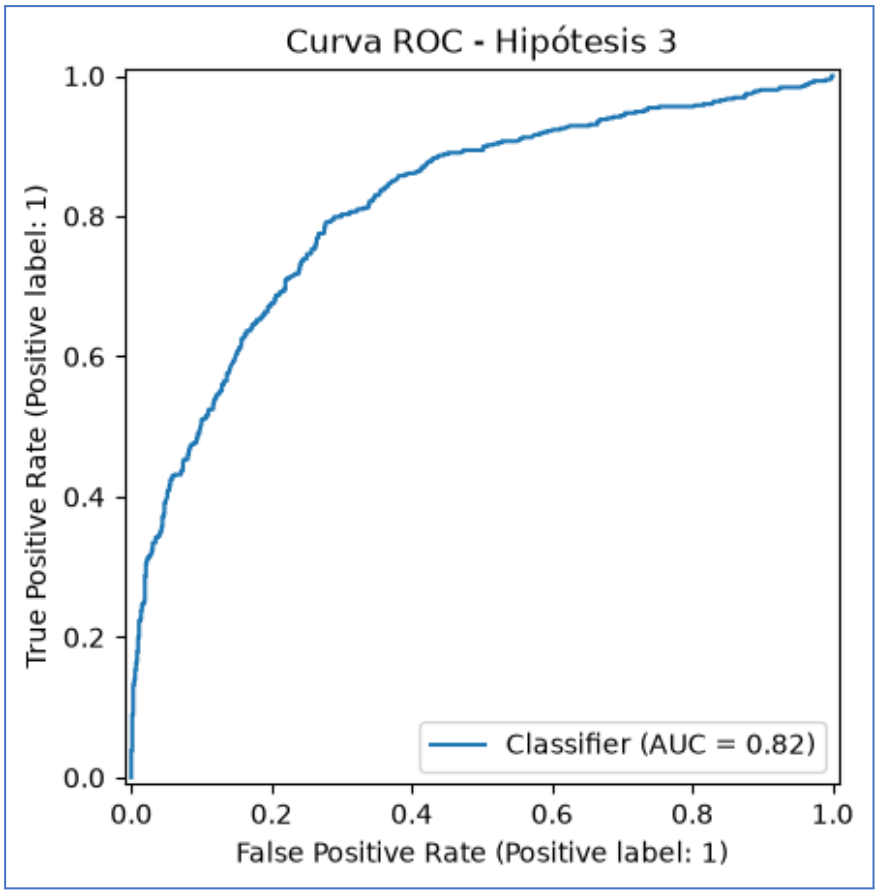
3.3.3. Resultados obtenidos y discusión

El modelo ajustado alcanzó una exactitud del 74,6% (0,746). Al analizar en detalle los gráficos generados:

- Matriz de confusión: permite visualizar los aciertos y errores del modelo al clasificar a los participantes. Se observa que el modelo clasificó correctamente a 539 personas sin CKD (verdaderos negativos) y a 405 personas con CKD (verdaderos positivos). En particular, se obtuvo un recall de 0,74 para la clase positiva, lo que indica que el modelo logró identificar correctamente al 74% de los pacientes que realmente padecian la enfermedad (405 de 547 casos).
- Curva ROC: muestra la capacidad discriminativa del modelo al variar el umbral de decisión. Obtuvimos un AUC de 0,816, lo que demuestra una buena capacidad para diferenciar entre pacientes con y sin la patología.

En consecuencia, los resultados muestran que las variables seleccionadas aportan información relevante para la clasificación, por lo que se respalda la hipótesis planteada de que estas tres variables se relacionan de forma conjunta con la presencia de CKD.





3.4. La mayoría de los casos de CKD identificados corresponde a personas de etnia blanca no hispana - *Hipótesis de la cátedra 1*.

3.4.1. Definición de la hipótesis

Hipótesis Nula (H0): La proporción de personas blancas no hispanas dentro del grupo con CKD es menor o igual al 50% ($p \leq 0.50$).

Hipótesis Alternativa (H1): La proporción de personas blancas no hispanas dentro del grupo con CKD representa más del 50% ($p > 0.50$).

3.4.2. Estrategia de abordaje

1. Filtramos el subgrupo de participantes identificados con CKD, total = 2734 personas.
2. Analizamos la distribución de casos según su grupo étnico mediante un gráfico de barras de frecuencias absolutas.
3. Calculamos la proporción relativa de participantes pertenecientes al grupo *Non-Hispanic White* respecto del total de casos de CKD y la representamos en un gráfico de torta.

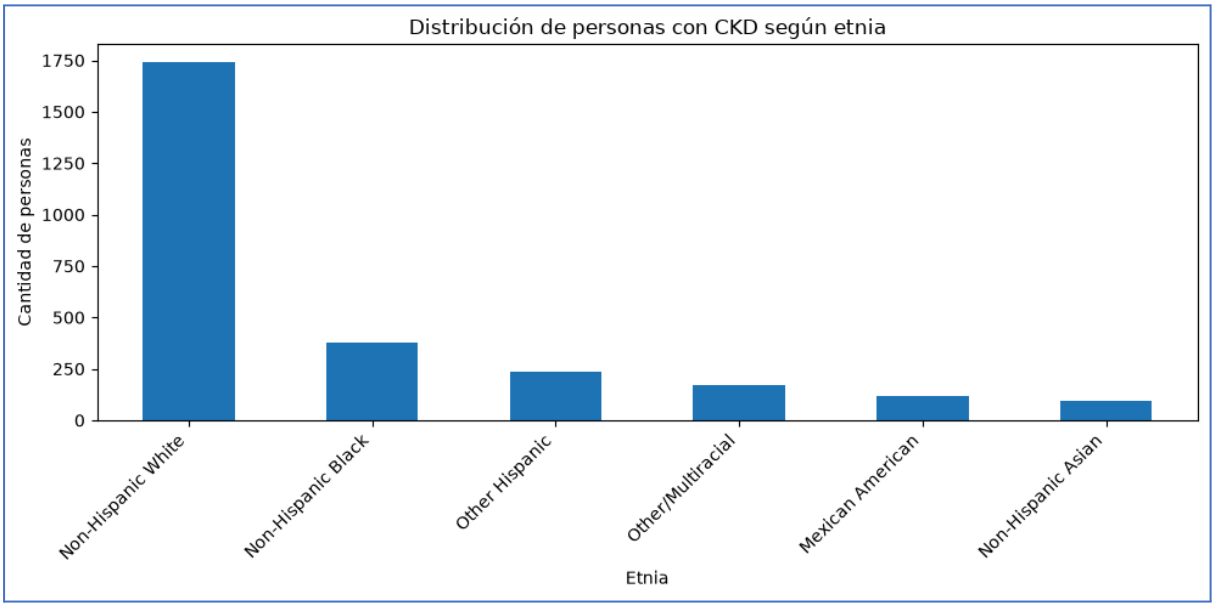
4. Aplicamos un binomtest para contrastar si la proporción observada supera de manera estadísticamente significativa el umbral del 50%.

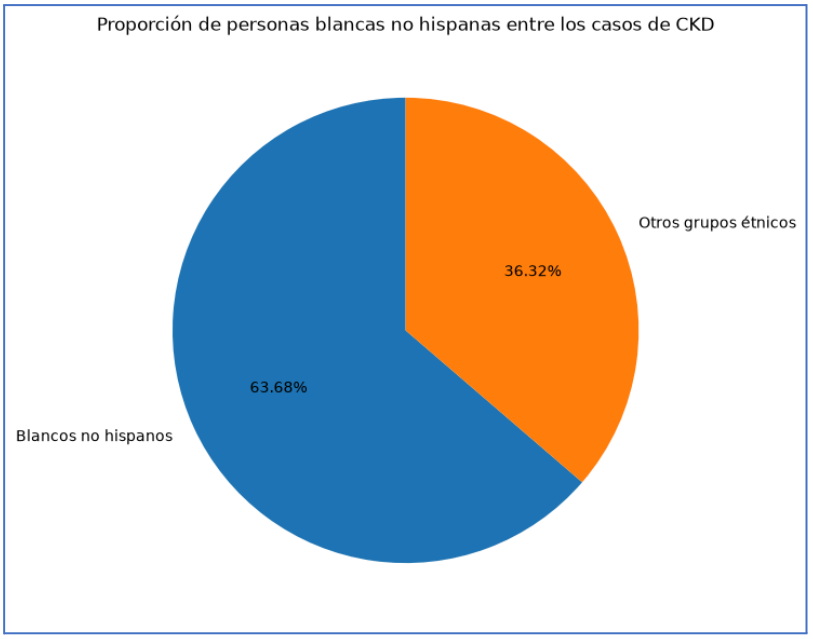
3.4.3. Resultados obtenidos y discusión

El análisis de frecuencias muestra que el grupo *Non-Hispanic White* presenta la mayor cantidad absoluta de casos, con 1741 personas, seguido por *Non-Hispanic Black* con 377 casos, *Other Hispanic* 235, *Other/Multiracial* 169, *Mexican American* 118 y *Non-Hispanic Asian* 94.

Al evaluar las proporciones relativas, las personas blancas no hispanas representan el 63,68% del total de participantes diagnosticados con CKD, mientras que el 36,32% restante se distribuye entre los demás grupos étnicos.

Dado que la proporción supera el 50%, y considerando que la prueba binomial obtuvo un valor $p = 3,59 \times 10^{-47}$ (inferior al nivel de significancia de $\alpha = 0,05$), existe evidencia estadística suficiente para **rechazar la hipótesis nula (H0) y aceptar la hipótesis planteada por la cátedra**: se sostiene que la mayoría de los casos de CKD identificados en este conjunto de datos corresponde a personas blancas no hispanas.





3.5. Las personas con CKD presentan valores de presión arterial sistólica significativamente más elevados que las personas sin CKD - *Hipótesis de la cátedra 2.*

3.5.1. Definición de la hipótesis

Hipótesis Nula (H0): La distribución de la presión arterial sistólica en personas con CKD es menor o igual que en la población sin la enfermedad.

Hipótesis Alternativa (H1): Las personas con CKD presentan niveles de presión arterial sistólica mayores que las personas sin CKD.

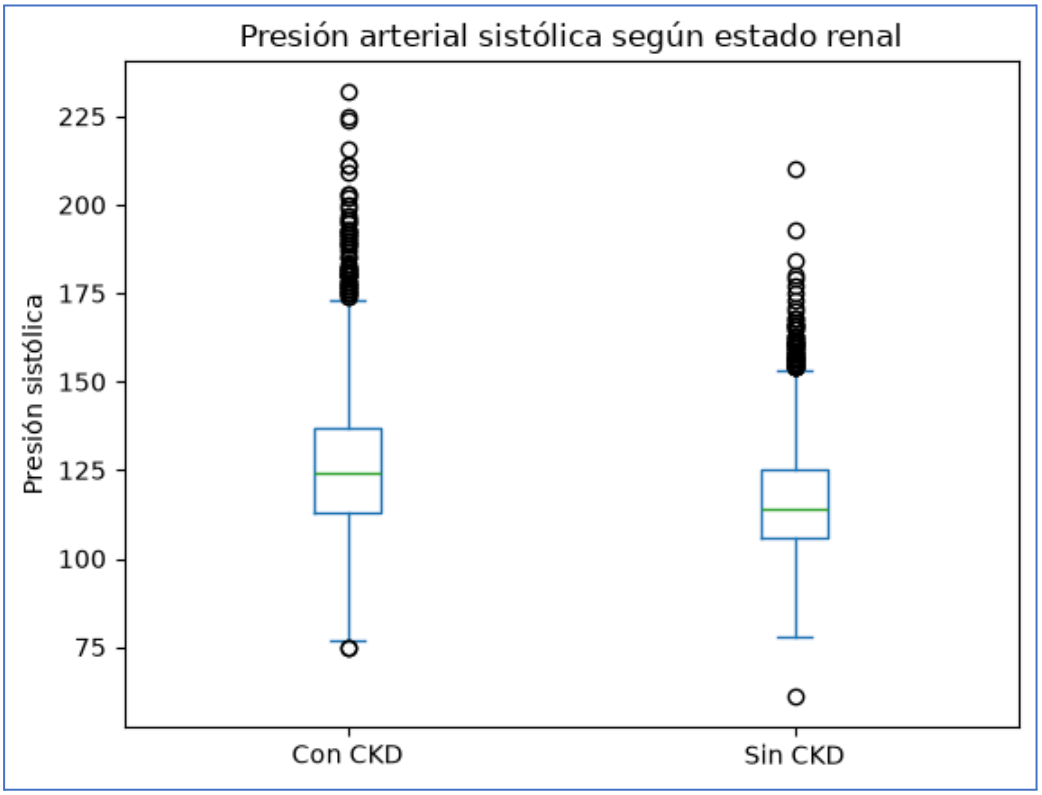
3.5.2. Estrategia de abordaje

Comparamos las mediciones de presión arterial sistólica (*bp_systolic*) entre el grupo con CKD y el grupo sano. Al evaluar la distribución de la variable y la presencia de valores atípicos, decidimos utilizar una prueba no paramétrica de comparación de medianas/rangos: el test de Mann-Whitney U con la alternativa unidireccional.

3.5.3. Resultados obtenidos y discusión

El grupo de pacientes con CKD registró un promedio de presión sistólica de 126,57 mmHg, mientras que el grupo sin CKD promedió 116,23 mmHg. La prueba Mann-Whitney U resultó en un valor $p = 1,81 \times 10^{-102}$. Al obtener una diferencia muy marcada, **rechazamos la hipótesis nula (H0) y confirmamos la hipótesis de la cátedra**: los pacientes con

enfermedad renal presentan niveles de presión arterial sistólica sustancialmente más elevados.



3.6. La edad, el sexo, el IMC, la presión arterial sistólica, la diabetes, el tabaquismo y el nivel socioeconómico se relacionan conjuntamente con la presencia de CKD - *Hipótesis de la cátedra 3*.

3.6.1. Definición de la hipótesis

Hipótesis Nula (H0): El conjunto ampliado de variables demográficas, metabólicas, clínicas y socioeconómicas no se relaciona significativamente con la presencia de CKD.

Hipótesis Alternativa (H1): Las variables de edad, sexo, IMC, presión arterial, diabetes, tabaquismo e ingresos familiares se relacionan de forma conjunta con la presencia de CKD.

3.6.2. Estrategia de abordaje

Ampliamos el modelo de regresión logística incluyendo las 7 variables seleccionadas:

- Numéricas: age, bmi, bp_systolic, pverty_income_ratio (imputadas por mediana y estandarizadas).
- Categóricas: *gender, diabetes_diagnosed, ever_smoked* (imputadas por moda y codificadas mediante One-hot Encoding).

Entrenamos la tubería con el 80% de los datos y evaluamos su desempeño predictivo sobre el 20% de evaluación restante

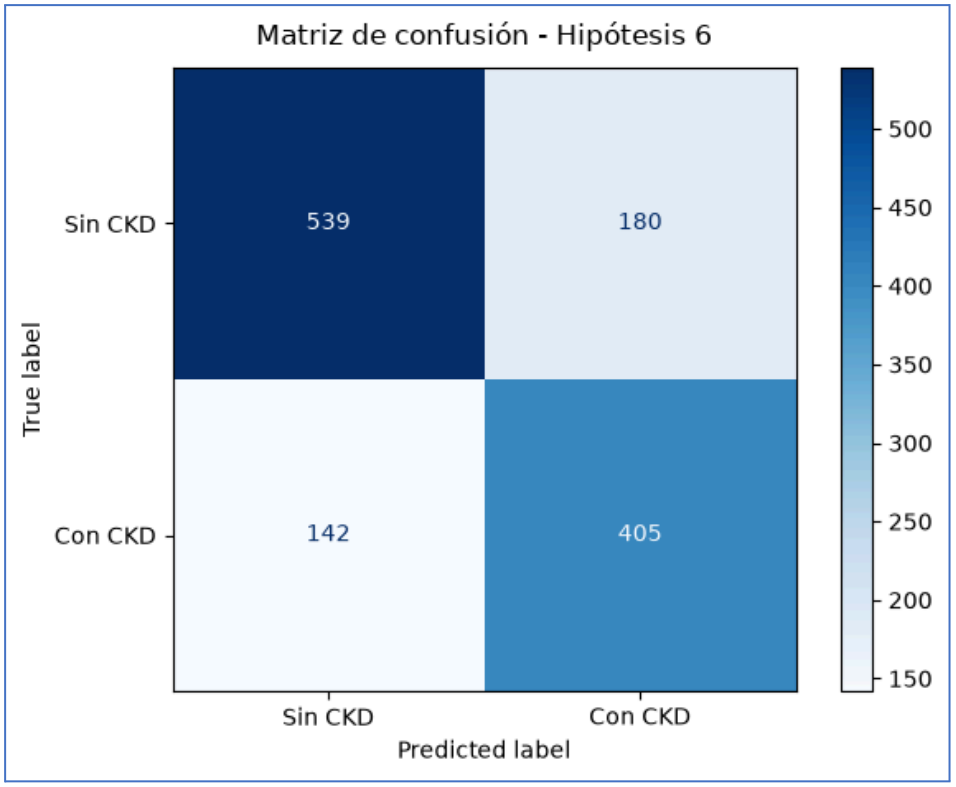
3.6.3. Resultados obtenidos y discusión

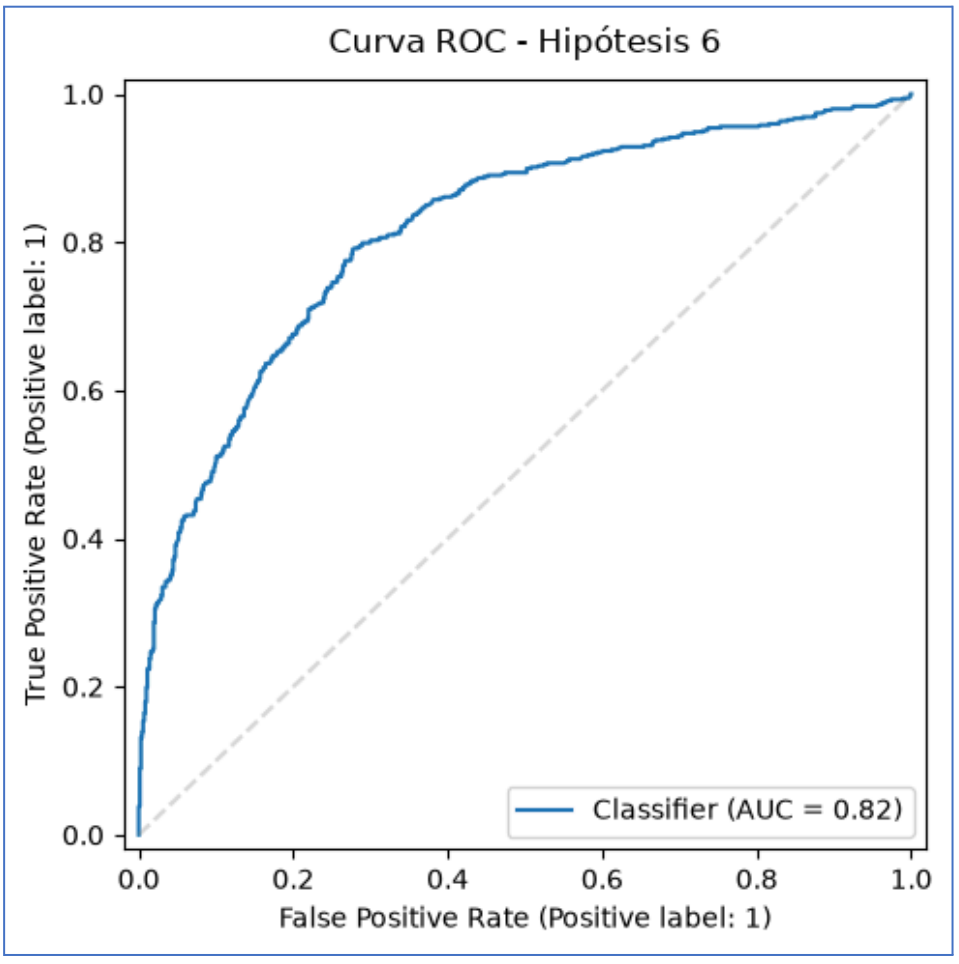
El modelo multivariado alcanzó una exactitud general del 74,8% (0,784) en el conjunto de prueba. A través de las visualizaciones generadas, podemos interpretar en detalle el desempeño de la clasificación:

- Matriz de confusión: Permite observar el balance entre los aciertos del modelo y sus errores de clasificación. El modelo identificó correctamente a 540 participantes sin CKD (verdaderos negativos) y a 407 participantes con CKD (verdaderos positivos). Sobre los pacientes con CKD, obtuvimos un recall de 0,74, lo que representa que el modelo logró capturar e identificar correctamente al 74% de las personas que efectivamente padecían la enfermedad (407 de 547 casos reales).
- Curva ROC: El modelo obtuvo un AUC de 0,816 (representado como 0,82 en el gráfico).

Al comparar estos resultados con los de la Hipótesis 3.3 (modelo simplificado con 3 variables), se observa que la incorporación de variables adicionales como el sexo, el índice de masa corporal, el tabaquismo y el nivel socioeconómico mantuvo la métrica de AUC en un nivel equivalente (0,816). Esto nos indica que, si bien el modelo amplio es sumamente sólido y discriminativo, la mayor parte de la capacidad explicativa y predictiva sobre la presencia de CKD se concentra en las variables biológicas centrales (edad, diagnóstico de diabetes y presión arterial sistólica).

En consecuencia, los resultados muestran que el conjunto amplio de variables sociodemográficas y clínicas se relaciona de forma conjunta con la patología, por lo que **se respalda la hipótesis planteada por la cátedra**.


Matriz de confusión - Hipótesis 6
Sin CKD
Con CKD
True label
539
180
142
405
Sin CKD
Con CKD
Predicted label
500
450
400
350
300
250
200
150


Curva ROC - Hipótesis 6
True Positive Rate (Positive label: 1)
False Positive Rate (Positive label: 1)
0.0
0.2
0.4
0.6
0.8
1.0
Classifier (AUC = 0.82)

4. Conclusiones

El análisis realizado sobre el conjunto de datos de salud y nutrición NHANES 2021-2023 permitió evaluar empíricamente la relación entre diversas características sociodemográficas, metabólicas y clínicas con la Enfermedad Renal Crónica (CKD).

A través de las distintas hipótesis planteadas y contrastadas estadísticamente, comprobamos que la edad avanzada (especialmente a partir de los 60 años), los antecedentes de diabetes y la presión arterial sistólica elevada y presencia de la enfermedad renal. por otro lado, observamos que dentro de la muestra analizada, la mayoría de los casos diagnosticados correspondió a personas de etnia blanca no hispana.

En cuanto al modelado predictivo multivariado, los algoritmos de regresión logística alcanzaron un desempeño sólido con un Área Bajo la Curva (AUC) de 0,816. El análisis comparativo entre el modelo simplificado (3 variables) y el modelo integral (7 variables) demostró que la adición de variables como el nivel socioeconómico, el tabaquismo, el sexo o el IMC no incrementó signficativamente la capacidad de discriminación, confirmando que el riesgo renal se concentra principalemente en los factores metabolicos y vasculares centrales.

A modo de conclusión y breve visualización dejamos una tabla con las hipótesis descritas rápidamente y sus resultados:

N°	Hipótesis planteada	Hipótesis nula (H0)	HIpótesis alternativa (H1)	Resultado
3.1	En la población con CKD, más del 50% de las personas tiene 60 años o más.	La proporción de personas de 60 años o más con CKD es menor o igual al 50% ($p \leq 0.50$).	La proporción de personas de 60 años o más con CKD es mayor al 50% ($p \geq 0.50$).	Se rechaza H0 ($p = 3,60\,x\,10^{-67}$). Más del 50% (66,39%) de los casos de CKD tienen 60 años o más.
3.2	Existe una asociación significativa entre el diagnóstico de diabetes y la presencia de enfermedad renal crónica.	El diagnóstico de diabetes y la presencia de CKD son variables independientes.	Existe una asociación estadísticamente significativa entre el diagnóstico de diabetes y la presencia de CKD.	Se rechaza H0 ($p = 2,12\,x\,10^{-41}$). Se confirma la asociación entre ambas condiciones.
3.3	La edad, el diagnóstico de diabetes y la presión arterial sistólica se relacionan conjuntamente con la presencia de CKD.	La combinación de edad, diabetes y presión sistólica no aporta capacidad predictiva sobre la presencia de CKD.	La combinación de edad, diabetes y presión sistólica se relaciona significativamente con la presencia de CKD.	Se soporta H1 (Exactitud: 74,6% / AUC: 0,816). Las tres variables aportan información relevante para clasificar la presencia de CKD.
3.4	La mayoría de los casos de CKD identificados corresponde a personas de etnia blanca no hispana.	La proporción de personas blancas no hispanas con CKD es menor o igual al 50% ($p \leq 0.50$).	La proporción de personas blancas no hispanas con CKD es mayor al 50% ($p \geq 0.50$).	Se rechaza H0 ($p = 3,59\,x\,10^{-47}$). Representan el 63,68% de los casos identificados.
3.5	Las personas con CKD presentan valores de presión arterial sistólica más elevados que las personas sin CKD.	La presión arterial sistólica en personas con CKD es menor o igual que en personas sin la enfermedad.	Las personas con CKD presentan niveles de presión arterial sistólica mayores que las personas sin CKD.	Se rechaza H0 ($p = (1,81\,x\,10^{-102}$). Los pacientes con CKD presentan niveles de presión arterial sistólica significativamente mayores.

3.6	La edad, el sexo, el IMC, la presión arterial, la diabetes, el tabaquismo y el nivel socioeconomico se relacionan conjuntamente con la presencia de CKD.	El conjunto ampliado de 7 variables no se relaciona significativamente con la presencia de CKD.	El conjunto ampliado de 7 variables se relaciona de forma conjunta con la presencia de CKD.	Se soporta H1 (Exactitud: 74,8% / AUC: 0,816). El modelo completo clasifica correctamente la patología.

5. Propuestas de acción y trabajo futuro

A partir de los hallazgos obtenidos, pensamos en sugerencias de acción en el ámbito clínico y metodológico:

1. **Tamizaje preventivo focalizado:** Diseñar campañas de detección temprana de CKD priorizando a la población mayor de 60 años y a pacientes con diagnóstico previo de diabetes o hipertensión arterial.
2. **Control de comorbilidades:** Reforzar el seguimiento estricto de la presión arterial y la glucemia en centros de atención primaria para ralentizar el deterioro del filtrado glomerular.
3. **Desarrollo de modelos predictivos avanzados:** Explorar el uso de algoritmos no lineales (como Random Forest o XGBoost) e imputaciones avanzadas sobre las variables de laboratorio con datos faltantes (eGFR, creatinina sérica) para evaluar posibles mejoras en la precisión diagnóstica de la enfermedad a tiempo.
    - Random Forest: combina las respuestas de cientos de árboles de decisión para quedarse con la opinión de la mayoría.
    - XGBoost: entrena modelos en cadena donde cada uno corrige los errores del anterior.
    - Ambos permiten detectar relaciones complejas en la salud que los modelos tradicionales no ven.

6. Referencias

- Centers for Disease Control and Prevention (CDC). National Health and Nutrition Examination Survey (NHANES) Datasets 2021–2023. U.S. Department of Health and Human Services.
- Kidney Disease: Improving Global Outcomes (KDIGO) CKD Work Group. KDIGO Clinical Practice Guideline for the Evaluation and Management of Chronic Kidney Disease.
- Cátedra de Fundamentos de la Ciencia de Datos (2026). Filminas, materiales y collabs. Guía del Trabajo Práctico Especial. Universidad Nacional del Centro de la Provincia de Buenos Aires (UNICEN).
- Google Gemini (modelo de lenguaje de inteligencia artificial). Utilizado como herramienta de exploración e indagación preliminar del conjunto de datos para consultar la viabilidad de relaciones entre variables y formular hipótesis de trabajo, así como de apoyo en la generación y revisión del código en Python.